

Curso Libre de Configuración 2: Análisis de Datos

Tarea 2 - Parte 2

Daniela Natareno – `dnatareno@unis.edu.gt`

Fecha de entrega: 20 de septiembre del 2026

3. Investigación – Segunda Parte: Monte Carlo

3.1. Fundamento: el estimador y su error

1. Estimador insesgado

Mostrar que:

$$I = \int_a^b f(x) dx = (b-a)E[f(U)], \quad U \sim \text{Unif}(a, b)$$

y que el estimador

$$\hat{I}_N = \frac{b-a}{N} \sum_{i=1}^N f(U_i)$$

es:

$$E[\hat{I}_N] = I$$

Se tiene:

$$I = \int_a^b f(x) dx$$

$$U \sim \text{Unif}(a, b)$$

pdf:

$$f_U(x) = \frac{1}{b-a}, \quad a \leq x \leq b$$

Def. del valor esperado para una VAC:

$$E[f(U)] = \int_a^b f(x) \frac{1}{b-a} dx$$

$$E[f(U)] = \frac{1}{b-a} \int_a^b f(x) dx$$

$$E[f(U)] = \frac{1}{b-a}(I)$$

$$\boxed{(b-a)E[f(U)] = I}$$

Estimador es insesgado:

$$\hat{I}_N = \frac{b-a}{N} \sum_{i=1}^N f(U_i)$$

Se aplica valor esperado a ambos lados:

$$\begin{aligned} E[\hat{I}_N] &= E \left[\frac{b-a}{N} \sum_{i=1}^N f(U_i) \right] \\ &= \left(\frac{b-a}{N} \right) E \left[\sum_{i=1}^N f(U_i) \right] \end{aligned}$$

Por propiedad de linealidad del valor esperado, el valor esperado de una suma es igual a la suma de los valores esperados:

$$= \left(\frac{b-a}{N} \right) \sum_{i=1}^N E[f(U_i)]$$

Cada U_i se genera de la misma $\text{Unif}(a, b)$, N veces:

$$= \left(\frac{b-a}{N} \right) N E[f(U)]$$

$$E[\hat{I}_N] = (b-a)E[f(U)]$$

Se sustituye el lado derecho con I , que se demostró anteriormente:

$$I = (b-a)E[f(U)]$$

$$\boxed{E[\hat{I}_N] = I}$$

2. Varianza y error estándar del estimador

Derivar la varianza $\text{Var}(\hat{I}_N)$ y mostrar que el error estándar del estimador decae como $O(N^{-1/2})$.

Se tiene:

$$\hat{I}_N = \frac{b-a}{N} \sum_{i=1}^N f(U_i)$$

Se aplica varianza a ambos lados

$$\text{Var}(\hat{I}_N) = \text{Var} \left(\frac{b-a}{N} \sum_{i=1}^N f(U_i) \right)$$

Se saca $\frac{b-a}{N}$, que es constante:

$$\text{Var}(\hat{I}_N) = \left(\frac{b-a}{N} \right)^2 \text{Var} \left(\sum_{i=1}^N f(U_i) \right)$$

Se asume que la muestra es independiente, ya que todo el inciso trabaja con el método de Monte Carlo y este establece que su muestra es iid (independiente e idénticamente distribuida).

Al ser independientes se puede utilizar:

$$\text{Var} \left(\sum_{i=1}^N f(U_i) \right) = \sum_{i=1}^N \text{Var}(f(U_i))$$

$$\text{Var}(f(U)) = \sigma_f^2$$

$$\sum_{i=1}^N \text{Var}(f(U_i)) = N\sigma_f^2$$

Sustituyendo:

$$\begin{aligned} \text{Var}(\hat{I}_N) &= \left(\frac{b-a}{N} \right)^2 N\sigma_f^2 \\ &= \frac{(b-a)^2}{N^2} N\sigma_f^2 \end{aligned}$$

Por lo tanto:

$$\text{Var}(\hat{I}_N) = \frac{(b-a)^2}{N} \sigma_f^2$$

Ahora se obtiene el error estándar:

$$\begin{aligned}
 SE(\hat{I}_N) &= \sqrt{\text{Var}(\hat{I}_N)} \\
 &= \sqrt{\frac{(b-a)^2}{N} \sigma_f^2} \\
 &= \frac{b-a}{\sqrt{N}} \sigma_f \\
 &= N^{-1/2} (b-a) \sigma_f
 \end{aligned}$$

Reescribiendo:

$$\frac{1}{\sqrt{N}}$$

Las constantes $(b-a)$ y σ_f no cambian respecto a N , entonces O permite obtener el comportamiento respecto a N :

$$\boxed{SE(\hat{I}_N) = O(N^{-1/2})}$$

La tasa de convergencia no depende de la dimensión del problema porque el número de dimensiones puede afectar la varianza de los valores evaluados, pero la dependencia del error estándar respecto al número de muestras N continúa siendo $N^{-1/2}$. Por lo tanto, aunque aumente la dimensión, la tasa de convergencia de Monte Carlo se mantiene como $O(N^{-1/2})$.

3. Intervalo de confianza del 95 %

Construir un intervalo de confianza del 95 % para $\hat{I}_N$ usando el Teorema del Límite Central.

Se tiene:

$$\hat{I}_N = \frac{b-a}{N} \sum_{i=1}^N f(U_i)$$

El Teorema del Límite Central dice que cuando N es suficientemente grande, entonces la distribución promedio de muestras iid se aproxima a una distribución normal:

$$\begin{aligned}
 \hat{I}_N &\approx N \left(I, \text{Var}(\hat{I}_N) \right) \\
 \hat{I}_N &\approx N \left(I, \frac{(b-a)^2}{N} \sigma_f^2 \right)
 \end{aligned}$$

La normal estándar se usará para construir el intervalo:

$$Z = \frac{\text{valor} - \text{media}}{\text{error estándar}}$$

En este caso:

$$\text{valor} = \hat{I}_N, \quad \text{media} = I, \quad SE(\hat{I}_N) = \frac{(b-a)\sigma_f}{\sqrt{N}}$$

Entonces:

$$Z = \frac{\hat{I}_N - I}{SE(\hat{I}_N)} \approx N(0, 1)$$

$$\boxed{Z = \frac{\hat{I}_N - I}{\frac{(b-a)\sigma_f}{\sqrt{N}}} \approx N(0, 1)}$$

El 95 % se encuentra aproximadamente entre $-1,96$ y $1,96$:

$$P(-1,96 \leq Z \leq 1,96) \approx 0,95$$

$$P\left(-1,96 \leq \frac{\hat{I}_N - I}{\frac{(b-a)\sigma_f}{\sqrt{N}}} \leq 1,96\right) \approx 0,95$$

$$(-1,96)SE(\hat{I}_N) \leq \hat{I}_N - I \leq (1,96)SE(\hat{I}_N)$$

$$\hat{I}_N - 1,96SE(\hat{I}_N) \leq I \leq \hat{I}_N + 1,96SE(\hat{I}_N)$$

$$IC_{95\%} = \left[\hat{I}_N - 1,96SE(\hat{I}_N), \hat{I}_N + 1,96SE(\hat{I}_N) \right]$$

$$\boxed{IC_{95\%} = \left[\hat{I}_N - 1,96 \left(\frac{(b-a)\sigma_f}{\sqrt{N}} \right), \hat{I}_N + 1,96 \left(\frac{(b-a)\sigma_f}{\sqrt{N}} \right) \right]}$$

Pero normalmente σ_f no se conoce, entonces:

$$\sigma_f^2 = \text{Var}(f(U))$$

Promedio muestral:

$$\bar{f} = \frac{1}{N} \sum_{i=1}^N f(U_i)$$

Varianza muestral:

$$S_f^2 = \frac{1}{N-1} \sum_{i=1}^N (f(U_i) - \bar{f})^2$$

Desviación estándar muestral:

$$S_f = \sqrt{S_f^2}$$

Con S_f se puede estimar σ_f :

$$\sigma_f \approx S_f$$

El error estándar estimado es:

$$\widehat{SE}(\hat{I}_N) = \frac{(b-a)S_f}{\sqrt{N}}$$

Ahora:

$$IC_{95\%} = \left[\hat{I}_N - 1,96 \left(\frac{(b-a)S_f}{\sqrt{N}} \right), \hat{I}_N + 1,96 \left(\frac{(b-a)S_f}{\sqrt{N}} \right) \right]$$

O sea:

$$\boxed{IC_{95\%} = \hat{I}_N \pm 1,96 \widehat{SE}(\hat{I}_N)}$$

3.2. Calentamiento: integrales en una dimensión

Se utilizó el estimador de Monte Carlo desarrollado anteriormente para aproximar las integrales propuestas. Para cada estimación se generaron muestras uniformes en el intervalo correspondiente y se calculó un intervalo de confianza del 95 %. Además, se compararon los resultados obtenidos con el valor teórico de cada integral.

a. Integral de $\sin(\pi x)$

Se aproximó la siguiente integral:

$$I = \int_0^1 \sin(\pi x) dx$$

El valor teórico utilizado como referencia fue:

$$I = \frac{2}{\pi} \approx 0,63661977$$

1. Estimación e intervalo de confianza Para realizar la estimación se utilizaron $N = 10000$ muestras y la semilla 8103. Inicialmente se utilizó el generador estándar `random` de Python. Aplicando el estimador de Monte Carlo se obtuvo:

$$\hat{I}_N = 0,63654476$$

El error estándar estimado fue:

$$\widehat{SE}(\hat{I}_N) = 0,00308289$$

Utilizando el intervalo de confianza desarrollado anteriormente:

$$IC_{95\%} = \hat{I}_N \pm 1,96\widehat{SE}(\hat{I}_N)$$

se obtuvo:

$$IC_{95\%} = [0,63050229, 0,64258722]$$

El valor teórico 0,63661977 se encuentra dentro del intervalo de confianza obtenido. El error absoluto respecto al valor teórico fue:

$$|\hat{I}_N - I| = |0,63654476 - 0,63661977| = 0,00007502$$

Por lo tanto, para esta ejecución la estimación obtenida mediante Monte Carlo presentó un valor cercano al valor teórico de la integral.

2. Estudio de convergencia Para analizar la convergencia del método se realizaron estimaciones utilizando diferentes tamaños de muestra distribuidos entre 10^1 y 10^6 . Para cada tamaño N se calculó el error absoluto:

$$|\hat{I}_N - I|$$

Los resultados se representaron en una gráfica en escala log-log, donde el eje horizontal corresponde al tamaño de muestra N y el eje vertical al error absoluto de la estimación.




Figura 1: Convergencia del estimador de Monte Carlo para la integral de $\sin(\pi x)$.

A partir de los valores obtenidos se realizó un ajuste lineal en escala log-log. La pendiente empírica obtenida fue:

$$-0,7265$$

La pendiente teórica esperada de acuerdo con la tasa de convergencia de Monte Carlo es:

$$-\frac{1}{2} = -0,5$$

La pendiente empírica obtenida no coincide exactamente con el valor teórico. Esta diferencia puede atribuirse a la variabilidad aleatoria propia del método de Monte Carlo y al

uso de una realización para cada tamaño de muestra. El error absoluto no necesariamente disminuye de manera continua al aumentar N , ya que una estimación particular puede encontrarse, por efecto de la muestra generada, más cerca o más lejos del valor teórico. Sin embargo, en la gráfica se observa una tendencia general decreciente del error conforme aumenta el tamaño de muestra.

3. Comparación de generadores Finalmente, se repitió la estimación utilizando dos generadores de números pseudoaleatorios. Se utilizó la librería estándar `random` de Python y la implementación propia de Mersenne Twister MT19937 desarrollada en la primera parte de la tarea.

Para mantener las mismas condiciones experimentales, ambos generadores utilizaron $N = 10000$ y la semilla 8103. Los resultados obtenidos fueron los siguientes:

Generador	Estimación	Error estándar	IC 95 %	Error absoluto
<code>random</code>	0.63654476	0.00308289	[0,63050229, 0,64258722]	0.00007502
MT19937 propio	0.63236931	0.00309206	[0,62630888, 0,63842975]	0.00425046

Cuadro 1: Comparación de los generadores utilizados para la estimación de la primera integral.

El valor teórico de la integral, 0,63661977, se encuentra dentro de los intervalos de confianza obtenidos con ambos generadores. Asimismo, los errores estándar fueron similares, con valores de 0,00308289 para `random` y 0,00309206 para MT19937 propio.

En esta ejecución, `random` produjo una estimación más cercana al valor teórico, con un error absoluto de 0,00007502, mientras que MT19937 propio presentó un error absoluto de 0,00425046. Sin embargo, esta diferencia corresponde a las secuencias pseudoaleatorias particulares generadas en el experimento y no implica, a partir de una sola ejecución, que uno de los generadores produzca en general mejores estimaciones de Monte Carlo que el otro.

b. Integral de la función normal estándar

Se aproximó la siguiente integral:

$$I = \int_0^2 \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$$

El valor teórico utilizado como referencia fue:

$$I \approx 0,47724987$$

1. Estimación e intervalo de confianza Para realizar la estimación se utilizaron $N = 10000$ muestras y la semilla 8103. Inicialmente se utilizó el generador estándar `random` de Python. Aplicando el estimador de Monte Carlo se obtuvo:

$$\hat{I}_N = 0,47652474$$

El error estándar estimado fue:

$$\widehat{SE}(\hat{I}_N) = 0,00230297$$

Utilizando el intervalo de confianza desarrollado anteriormente:

$$IC_{95\%} = \hat{I}_N \pm 1,96\widehat{SE}(\hat{I}_N)$$

se obtuvo:

$$IC_{95\%} = [0,47201092, 0,48103857]$$

El valor teórico 0,47724987 se encuentra dentro del intervalo de confianza obtenido. El error absoluto respecto al valor teórico fue:

$$|\hat{I}_N - I| = |0,47652474 - 0,47724987| = 0,00072513$$

Por lo tanto, para esta ejecución la estimación obtenida mediante Monte Carlo presentó un valor cercano al valor teórico de la integral.

2. Estudio de convergencia Para analizar la convergencia del método se realizaron estimaciones utilizando diferentes tamaños de muestra distribuidos entre 10^1 y 10^6 . Para cada tamaño N se calculó el error absoluto:

$$|\hat{I}_N - I|$$

Los resultados se representaron en una gráfica en escala log-log, donde el eje horizontal corresponde al tamaño de muestra N y el eje vertical al error absoluto de la estimación.




Figura 2: Convergencia del estimador de Monte Carlo para la integral de la función normal estándar.

A partir de los valores obtenidos se realizó un ajuste lineal en escala log-log. La pendiente empírica obtenida fue:

$$-0,5337$$

La pendiente teórica esperada de acuerdo con la tasa de convergencia de Monte Carlo es:

$$-\frac{1}{2} = -0,5$$

La pendiente empírica obtenida es cercana al valor teórico de $-0,5$, mostrando un comportamiento consistente con la tasa de convergencia esperada de Monte Carlo, $O(N^{-1/2})$. Aunque los errores absolutos presentan variaciones entre diferentes tamaños de muestra, en la gráfica se observa una tendencia general decreciente conforme aumenta N .

3. Comparación de generadores Finalmente, se repitió la estimación utilizando dos generadores de números pseudoaleatorios. Se utilizó la librería estándar `random` de Python y la implementación propia de Mersenne Twister MT19937 desarrollada en la primera parte de la tarea.

Para mantener las mismas condiciones experimentales, ambos generadores utilizaron $N = 10000$ y la semilla 8103. Los resultados obtenidos fueron los siguientes:

Generador	Estimación	Error estándar	IC 95 %	Error absoluto
random	0.47652474	0.00230297	[0,47201092, 0,48103857]	0.00072513
MT19937 propio	0.47801389	0.00231373	[0,47347899, 0,48254880]	0.00076402

Cuadro 2: Comparación de los generadores utilizados para la estimación de la segunda integral.

El valor teórico de la integral, 0,47724987, se encuentra dentro de los intervalos de confianza obtenidos con ambos generadores. Asimismo, los errores estándar fueron similares, con valores de 0,00230297 para **random** y 0,00231373 para MT19937 propio.

En esta ejecución, **random** presentó un error absoluto de 0,00072513, mientras que MT19937 propio presentó un error absoluto de 0,00076402. Ambos resultados fueron cercanos al valor teórico y la diferencia entre sus errores absolutos fue pequeña. Al igual que en la integral anterior, los resultados corresponden a las secuencias pseudoaleatorias particulares generadas y una sola ejecución no permite concluir que uno de los generadores produzca en general mejores estimaciones que el otro.

3.3. Alta dimensión y la maldición de la dimensionalidad

Se estudió el volumen de la bola unitaria en d dimensiones:

$$B_d = \{x \in \mathbb{R}^d : \|x\|_2 \leq 1\}.$$

Su volumen puede expresarse como:

$$V_d = \int_{[-1,1]^d} \mathbf{1}[x_1^2 + \dots + x_d^2 \leq 1] dx.$$

El valor exacto utilizado únicamente como referencia para calcular los errores fue:

$$V_d = \frac{\pi^{d/2}}{\Gamma\left(\frac{d}{2} + 1\right)}.$$

1. Estimación mediante Monte Carlo

Para estimar el volumen mediante Monte Carlo se generaron puntos uniformemente distribuidos en el hipercubo $[-1, 1]^d$. Para cada punto se verificó si:

$$x_1^2 + x_2^2 + \dots + x_d^2 \leq 1.$$

Si se cumple esta condición, el punto se encuentra dentro de la bola unitaria. La proporción de puntos que se encuentran dentro de la bola permite estimar la fracción del volumen del hipercubo ocupada por esta.

El volumen del hipercubo $[-1, 1]^d$ es:

$$2^d.$$

Si N_{dentro} representa la cantidad de puntos que cumplen la condición y N es el número total de puntos generados, entonces:

$$\hat{p} = \frac{N_{\text{dentro}}}{N}.$$

Por lo tanto, el estimador utilizado para el volumen fue:

$$\hat{V}_d = 2^d \hat{p} = 2^d \frac{N_{\text{dentro}}}{N}$$

Debido a que la pertenencia de un punto a la bola puede representarse mediante una variable Bernoulli, el error estándar estimado se calculó mediante:

$$\widehat{SE}(\hat{V}_d) = 2^d \sqrt{\frac{\hat{p}(1 - \hat{p})}{N}}.$$

El intervalo de confianza del 95 % se calculó como:

$$IC_{95\%} = \hat{V}_d \pm 1,96\widehat{SE}(\hat{V}_d).$$

Se utilizaron $N = 1000000$ puntos, una semilla de 8103 y las dimensiones $d = 2, 5, 10, 20$. Los resultados obtenidos fueron:

d	Puntos dentro	Estimación	IC 95 %	Valor teórico
2	785484	3.14193600	[3,13871779, 3,14515421]	3.14159265
5	164808	5.27385600	[5,25058643, 5,29712557]	5.26378901
10	2520	2.58048000	[2,47985442, 2,68110558]	2.55016404
20	1	1.04857600	[-1,00663193, 3,10378393]	0.02580689

Cuadro 3: Estimación mediante Monte Carlo del volumen de la bola unitaria para diferentes dimensiones.

Para $d = 2$, $d = 5$ y $d = 10$, las estimaciones obtenidas fueron cercanas a sus respectivos valores teóricos y estos se encuentran dentro de los intervalos de confianza calculados.

Al aumentar la dimensión se observa una reducción considerable en la cantidad de puntos que caen dentro de la bola. Para $d = 2$, 785484 de los 1000000 puntos generados se encontraron dentro de ella, mientras que para $d = 10$ solamente se encontraron 2520. En $d = 20$, únicamente un punto de los 1000000 generados se encontró dentro de la bola.

Debido a que para $d = 20$ solamente se obtuvo un punto dentro de la bola, la estimación presenta un error estándar elevado y un intervalo de confianza muy amplio. El límite inferior obtenido es negativo debido al uso de la aproximación normal para construir el intervalo de confianza, aunque un volumen no puede tomar valores negativos. En este caso, la pequeña cantidad de puntos dentro de la bola hace que esta aproximación sea poco adecuada y evidencia la dificultad de utilizar muestreo uniforme en el hipercubo cuando aumenta la dimensión.

2. Comparación con una rejilla determinística

Se implementó una rejilla determinística dividiendo cada eje del hipercubo $[-1, 1]^d$ en m partes y evaluando el centro de cada celda. El número total de puntos requeridos por la rejilla es:

$$N_{\text{rejilla}} = m^d.$$

Para comparar la rejilla con Monte Carlo se utilizó un presupuesto máximo de 1000000 puntos. Para cada dimensión se seleccionó el mayor valor entero de m que cumpliera:

$$m^d \leq 1000000.$$

Monte Carlo utilizó posteriormente la misma cantidad de puntos que la rejilla para realizar la comparación con el mismo presupuesto de evaluaciones.

Los resultados obtenidos fueron:

d	m	Puntos	Error MC	Error rejilla
2	1000	1000000	0.00034335	0.00023135
5	15	759375	0.00698761	0.07816193
10	3	59049	0.08574851	0.93548347
20	1	1	0.02580689	1048575.97419311

Cuadro 4: Comparación del error de Monte Carlo y la rejilla determinística utilizando el mismo presupuesto de puntos.

En dimensión $d = 2$, la rejilla determinística obtuvo un error ligeramente menor que Monte Carlo. Sin embargo, al aumentar la dimensión, el número de divisiones que puede utilizarse en cada eje disminuye rápidamente para respetar el presupuesto establecido. Para $d = 5$, solamente pueden utilizarse 15 divisiones por eje y para $d = 10$, únicamente 3.

Para $d = 20$, el presupuesto obliga a utilizar $m = 1$, por lo que la rejilla está formada únicamente por el centro del hipercubo. Este punto se encuentra dentro de la bola y, por lo tanto, la rejilla estima que todo el volumen del hipercubo pertenece a ella, produciendo una estimación de $2^{20} = 1048576$. Esto produce un error considerable y muestra la pérdida de resolución de una rejilla determinística cuando aumenta la dimensión y se mantiene fijo el presupuesto de evaluaciones.

Además, se calculó el número de puntos necesarios al mantener $m = 10$ divisiones en cada eje:

Dimensión d	Número de puntos 10^d
2	$10^2 = 100$
5	$10^5 = 100000$
10	$10^{10} = 10000000000$
20	$10^{20} = 100000000000000000000$

Cuadro 5: Número de puntos requeridos por una rejilla con $m = 10$ divisiones por eje.

El número de puntos de la rejilla crece exponencialmente con la dimensión. Por lo tanto, mantener la misma resolución por eje se vuelve computacionalmente impráctico en dimensiones altas. Este comportamiento corresponde a la maldición de la dimensionalidad.

3. Fracción de volumen ocupada por la bola

Finalmente, se analizó la fracción del volumen del hipercubo $[-1, 1]^d$ que ocupa la bola unitaria. Esta fracción está dada por:

$$\frac{V_d}{2^d}.$$

Se calculó esta relación para dimensiones desde $d = 1$ hasta $d = 20$.




Figura 3: Fracción del volumen del hipercubo ocupada por la bola unitaria conforme aumenta la dimensión.

La gráfica muestra que la fracción del hipercubo ocupada por la bola disminuye rápidamente conforme aumenta la dimensión. Por ejemplo:

$$\frac{V_2}{2^2} \approx 0,785398,$$

$$\frac{V_5}{2^5} \approx 0,164493,$$

$$\frac{V_{10}}{2^{10}} \approx 0,002490,$$

mientras que para $d = 20$:

$$\frac{V_{20}}{2^{20}} \approx 2,4611 \times 10^{-8}.$$

Por lo tanto, en dimensiones altas la bola ocupa una fracción extremadamente pequeña del hipercubo que la contiene. Como consecuencia, al generar puntos uniformemente dentro

del hipercubo, la gran mayoría se encuentra fuera de la bola y aporta un valor cero a la función indicadora utilizada por el estimador.

Esto explica el resultado observado anteriormente para $d = 20$, donde únicamente uno de los 1000000 puntos generados cayó dentro de la bola. Por esta razón, aunque la tasa general de convergencia de Monte Carlo no depende directamente de la dimensión, este esquema particular de muestreo se vuelve ineficiente en dimensiones altas debido a que la región de interés ocupa una fracción cada vez menor del espacio de muestreo.

3.4. Reducción de varianza

El error estándar de un estimador de Monte Carlo depende de la desviación estándar y del número de muestras utilizadas:

$$SE \propto \frac{\sigma}{\sqrt{N}}.$$

Por lo tanto, una forma de disminuir el error consiste en aumentar el número de muestras N . Sin embargo, esto también aumenta el costo computacional. Otra alternativa consiste en reducir la varianza del estimador.

Para estudiar este enfoque se utilizaron dos técnicas de reducción de varianza: variables antitéticas y variables de control.

1. Variables antitéticas

Las variables antitéticas son una técnica de reducción de varianza que busca generar pares de variables relacionadas negativamente. La idea es que las variaciones producidas por una de las muestras puedan ser compensadas por las variaciones de su correspondiente muestra antitética.

Para una variable:

$$U \sim \text{Unif}(0, 1),$$

se puede construir su variable antitética como:

$$U' = 1 - U.$$

Ambas variables tienen la misma distribución:

$$U \sim \text{Unif}(0, 1), \quad 1 - U \sim \text{Unif}(0, 1).$$

El estimador utilizando un par antitético puede expresarse como:

$$\hat{\theta}_{AV} = \frac{f(U) + f(1 - U)}{2}.$$

La varianza de este estimador es:

$$\text{Var}\left(\frac{f(U) + f(1 - U)}{2}\right) = \frac{1}{4} [\text{Var}(f(U)) + \text{Var}(f(1 - U)) + 2 \text{Cov}(f(U), f(1 - U))].$$

Como U y $1 - U$ tienen la misma distribución:

$$\text{Var}(f(U)) = \text{Var}(f(1 - U)).$$

Entonces:

$$\text{Var}(\hat{\theta}_{AV}) = \frac{1}{2} \text{Var}(f(U)) + \frac{1}{2} \text{Cov}(f(U), f(1 - U)).$$

Si:

$$\text{Cov}(f(U), f(1 - U)) < 0,$$

el término de covarianza disminuye la varianza del estimador. Por esta razón, la técnica funciona especialmente bien cuando las evaluaciones de la función correspondientes a las muestras antitéticas presentan una relación negativa.

Sin embargo, la técnica no siempre produce una reducción de varianza. Su efectividad depende del comportamiento del integrando. Si la covarianza entre las evaluaciones es cercana a cero, la reducción será pequeña, y si la covarianza es positiva, la técnica puede incluso aumentar la varianza.

Aplicación a la integral de la función normal estándar Para aplicar la técnica se utilizó la segunda integral de la sección 3.2:

$$I = \int_0^2 \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx.$$

En este caso:

$$U \sim \text{Unif}(0, 2).$$

Para un intervalo general $[a, b]$, la variable antitética se construye mediante:

$$U' = a + b - U.$$

Como $a = 0$ y $b = 2$:

$$\boxed{U' = 2 - U}$$

La función evaluada es:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}.$$

Esta función es decreciente en el intervalo $[0, 2]$. Por lo tanto, cuando U toma un valor pequeño, $2 - U$ toma un valor grande, y viceversa. Esto permite que las evaluaciones $f(U)$ y $f(2 - U)$ puedan compensarse.

Si se generan M pares antitéticos, el estimador utilizado para esta integral es:

$$\boxed{\hat{I}_{AV} = \frac{2}{M} \sum_{i=1}^M \frac{f(U_i) + f(2 - U_i)}{2}}$$

donde M representa el número de pares antitéticos. Como cada par requiere dos evaluaciones de la función, el número total de evaluaciones es:

$$N = 2M.$$

En el experimento se utilizaron $N = 10000$ evaluaciones, por lo que:

$$M = 5000.$$

El uso de la variable antitética no modifica el valor esperado del estimador. Como:

$$U \sim \text{Unif}(0, 2),$$

también se cumple que:

$$2 - U \sim \text{Unif}(0, 2).$$

Por lo tanto:

$$E[f(U)] = E[f(2 - U)].$$

De la relación desarrollada anteriormente para el estimador de Monte Carlo:

$$I = (b - a)E[f(U)],$$

y como $b - a = 2$:

$$I = 2E[f(U)].$$

Entonces:

$$E[f(U)] = \frac{I}{2}.$$

Aplicando valor esperado al promedio del par antitético:

$$E \left[\frac{f(U) + f(2 - U)}{2} \right] = \frac{1}{2} (E[f(U)] + E[f(2 - U)]).$$

Como ambas variables tienen la misma distribución:

$$= \frac{1}{2} \left(\frac{I}{2} + \frac{I}{2} \right) = \frac{I}{2}.$$

Finalmente, el estimador de la integral multiplica este promedio por la longitud del intervalo, que es 2:

$$E[\hat{I}_{AV}] = 2 \left(\frac{I}{2} \right).$$

Por lo tanto:

$$E[\hat{I}_{AV}] = I$$

Así, el estimador con variables antitéticas continúa siendo insesgado. La modificación no busca cambiar el valor esperado de la estimación, sino reducir su varianza.

Resultados experimentales Para comparar el desempeño del método se realizaron dos estimaciones de la integral: una mediante Monte Carlo simple y otra utilizando variables antitéticas. En ambos casos se utilizó la semilla 8103 y un total de 10000 evaluaciones de la función. Para el método antitético se generaron 5000 valores uniformes independientes y, para cada uno, su correspondiente variable antitética, obteniendo así 5000 pares y 10000 evaluaciones en total. De esta manera, ambos métodos se compararon utilizando el mismo número de evaluaciones de la función.

Los resultados obtenidos fueron:

Método	Estimación	Varianza	Error estándar	Error absoluto
Monte Carlo simple	0.47652474	0.0000053037	0.00230297	0.00072513
Variables antitéticas	0.47730485	0.0000000146	0.00012099	0.00005498

Cuadro 6: Comparación entre Monte Carlo simple y variables antitéticas.

El valor teórico de la integral es:

$$I \approx 0,47724987.$$

Los intervalos de confianza del 95 % obtenidos fueron:

$$IC_{95\%}^{MC} = [0,47201092, 0,48103857],$$

y para variables antitéticas:

$$IC_{95\%}^{AV} = [0,47706771, 0,47754198].$$

En ambos casos el valor teórico se encuentra dentro del intervalo de confianza. Sin embargo, el intervalo obtenido mediante variables antitéticas es considerablemente más estrecho, lo cual corresponde a la reducción observada en el error estándar del estimador.

Para cuantificar la reducción de varianza se calculó el cociente entre la varianza del estimador de Monte Carlo simple y la varianza del estimador antitético:

$$\text{Factor de reducción} = \frac{\text{Var}(\hat{I}_{MC})}{\text{Var}(\hat{I}_{AV})}.$$

Con los valores obtenidos:

$$\boxed{\text{Factor de reducción} = 362,3240}$$

Esto significa que, para este experimento, la varianza del estimador de Monte Carlo simple fue aproximadamente 362,324 veces la varianza obtenida mediante variables antitéticas.

También se calculó la reducción porcentual de la varianza:

$$\text{Reducción} = \left(1 - \frac{\text{Var}(\hat{I}_{AV})}{\text{Var}(\hat{I}_{MC})} \right) 100.$$

El resultado fue:

$$\boxed{\text{Reducción de varianza} = 99,72 \%}$$

La reducción obtenida se debe al comportamiento de la función seleccionada en el intervalo $[0, 2]$. Como $f(x)$ es decreciente, un valor pequeño de U se combina con un valor grande de $2 - U$, y viceversa. Esto genera una relación negativa entre $f(U)$ y $f(2 - U)$, permitiendo que sus variaciones se compensen al formar cada promedio antitético.

Finalmente, el factor de reducción de varianza puede interpretarse como un *speedup* equivalente de:

$$\boxed{362,3240 \times}$$

Bajo la relación usual de Monte Carlo, donde la varianza del estimador disminuye proporcionalmente a $1/N$, este valor indica que Monte Carlo simple necesitaría aproximadamente 362,324 veces más evaluaciones para alcanzar una varianza comparable a la obtenida mediante variables antitéticas en este experimento. Este *speedup* es una medida de eficiencia estadística y no significa que el programa se ejecute literalmente 362,324 veces más rápido.

En esta ejecución, el estimador antitético también presentó un error absoluto menor, pasando de 0,00072513 con Monte Carlo simple a 0,00005498. Sin embargo, la efectividad de la técnica debe evaluarse principalmente mediante la reducción de la varianza y del error estándar, ya que el error absoluto de una ejecución particular también depende de la muestra pseudoaleatoria generada.

2. Variables de control

Las variables de control son una técnica de reducción de varianza que utiliza una variable auxiliar relacionada con la variable que se desea estimar y cuyo valor esperado es conocido. La información proporcionada por esta variable permite corregir las variaciones producidas por el muestreo de Monte Carlo sin modificar el valor esperado del estimador.

Sea Y la variable cuyo valor esperado se desea estimar:

$$\theta = E[Y].$$

Se introduce una variable de control X , para la cual se conoce:

$$E[X] = \mu_X.$$

El estimador utilizando una variable de control puede construirse como:

$$Y_{CV} = Y - c(X - \mu_X)$$

donde c es una constante que determina cuánto se utiliza la información de la variable de control para ajustar la estimación.

El uso de la variable de control no modifica el valor esperado del estimador. Aplicando valor esperado:

$$E[Y_{CV}] = E[Y - c(X - \mu_X)].$$

Por linealidad del valor esperado:

$$E[Y_{CV}] = E[Y] - c(E[X] - \mu_X).$$

Como:

$$E[X] = \mu_X,$$

entonces:

$$E[Y_{CV}] = E[Y] - c(\mu_X - \mu_X).$$

Por lo tanto:

$$E[Y_{CV}] = E[Y] = \theta$$

Así, el estimador con variable de control continúa siendo insesgado.

Para analizar la reducción de varianza se tiene:

$$\text{Var}(Y_{CV}) = \text{Var}(Y - c(X - \mu_X)).$$

Como μ_X es una constante, no afecta la varianza:

$$\text{Var}(Y_{CV}) = \text{Var}(Y - cX).$$

Utilizando la propiedad de la varianza de una combinación lineal:

$$\text{Var}(Y_{CV}) = \text{Var}(Y) + c^2 \text{Var}(X) - 2c \text{Cov}(Y, X).$$

Por lo tanto:

$$\text{Var}(Y_{CV}) = \text{Var}(Y) + c^2 \text{Var}(X) - 2c \text{Cov}(Y, X)$$

El valor de c puede seleccionarse de manera que la varianza del estimador sea mínima. Para encontrar este valor se deriva la expresión anterior respecto a c :

$$\frac{d}{dc} \text{Var}(Y_{CV}) = 2c \text{Var}(X) - 2 \text{Cov}(Y, X).$$

Se iguala a cero:

$$2c \text{Var}(X) - 2 \text{Cov}(Y, X) = 0.$$

Entonces:

$$c \text{Var}(X) = \text{Cov}(Y, X).$$

Por lo tanto, el coeficiente óptimo es:

$$c^* = \frac{\text{Cov}(Y, X)}{\text{Var}(X)}$$

La efectividad de esta técnica depende de la relación existente entre Y y la variable de control X . Cuanto mayor sea la relación entre ambas variables, mayor puede ser la reducción de varianza obtenida.

Aplicación a la integral de la función normal estándar Para aplicar la técnica se utilizó nuevamente la segunda integral de la sección 3.2:

$$I = \int_0^2 \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx.$$

Si:

$$U \sim \text{Unif}(0, 2),$$

la integral puede expresarse como:

$$I = 2E[f(U)],$$

donde:

$$f(U) = \frac{1}{\sqrt{2\pi}} e^{-U^2/2}.$$

Por lo tanto, se toma como variable de interés:

$$Y = f(U).$$

Como variable de control se utiliza:

$$X = U$$

Esta elección permite conocer exactamente el valor esperado de la variable de control. Para una variable uniforme en el intervalo $[a, b]$:

$$E[U] = \frac{a+b}{2}.$$

Como en este caso $a = 0$ y $b = 2$:

$$E[U] = 1$$

Por lo tanto:

$$\mu_X = 1.$$

Además, esta variable se encuentra relacionada con $f(U)$. La función $f(U)$ es decreciente en el intervalo $[0, 2]$, por lo que conforme U aumenta, $f(U)$ disminuye. Esta relación puede aprovecharse para reducir la varianza del estimador.

El valor corregido mediante la variable de control es:

$$Y_{CV} = f(U) - c(U - 1).$$

El coeficiente óptimo correspondiente es:

$$c^* = \frac{\text{Cov}(f(U), U)}{\text{Var}(U)}$$

Como el coeficiente óptimo depende de cantidades poblacionales que no se conocen directamente durante la simulación, este se estima a partir de las muestras generadas:

$$\hat{c} = \frac{\widehat{\text{Cov}}(f(U), U)}{\widehat{\text{Var}}(U)}$$

Finalmente, utilizando N muestras, el estimador de la integral con variable de control es:

$$\hat{I}_{CV} = \frac{2}{N} \sum_{i=1}^N [f(U_i) - \hat{c}(U_i - 1)]$$

En este caso, cada muestra requiere una evaluación de $f(U_i)$. Por lo tanto, al utilizar $N = 10000$ muestras se realizan 10000 evaluaciones de la función, permitiendo comparar el método con Monte Carlo simple utilizando el mismo número de evaluaciones.

A partir de las muestras generadas se obtuvo una covarianza estimada de:

$$\widehat{\text{Cov}}(f(U), U) = -0,06618401.$$

Como se esperaba debido al comportamiento decreciente de la función, la covarianza obtenida fue negativa. El coeficiente estimado fue:

$$\hat{c} = -0,19845747$$

El signo negativo del coeficiente es consistente con la relación inversa existente entre U y $f(U)$ en el intervalo estudiado.

Resultados experimentales Para comparar el desempeño del método se realizaron dos estimaciones de la integral: una mediante Monte Carlo simple y otra utilizando variables de control. En ambos casos se utilizaron $N = 10000$ evaluaciones de la función y la semilla 8103. De esta manera, ambos métodos fueron comparados utilizando el mismo presupuesto de evaluaciones.

Los resultados obtenidos fueron:

Método	Estimación	Varianza	Error estándar	Error absoluto
Monte Carlo simple	0.47652474	0.0000053037	0.00230297	0.00072513
Variables de control	0.47739324	0.0000000498	0.00022315	0.00014337

Cuadro 7: Comparación entre Monte Carlo simple y variables de control.

El valor teórico de la integral es:

$$I \approx 0,47724987.$$

Los intervalos de confianza del 95 % obtenidos fueron:

$$IC_{95\%}^{MC} = [0,47201092, 0,48103857],$$

y para variables de control:

$$IC_{95\%}^{CV} = [0,47695587, 0,47783061].$$

En ambos casos el valor teórico se encuentra dentro del intervalo de confianza. Sin embargo, el intervalo obtenido mediante variables de control es considerablemente más estrecho que el obtenido mediante Monte Carlo simple, lo cual corresponde a la disminución observada en la varianza y en el error estándar.

Para cuantificar la reducción de varianza se calculó:

$$\text{Factor de reducción} = \frac{\text{Var}(\hat{I}_{MC})}{\text{Var}(\hat{I}_{CV})}.$$

Con los valores obtenidos:

$$\text{Factor de reducción} = 106,5110$$

Esto significa que, para este experimento, la varianza del estimador de Monte Carlo simple fue aproximadamente 106,511 veces la varianza obtenida mediante variables de control.

También se calculó la reducción porcentual de la varianza:

$$\text{Reducción} = \left(1 - \frac{\text{Var}(\hat{I}_{CV})}{\text{Var}(\hat{I}_{MC})}\right) 100.$$

El resultado fue:

Reducción de varianza = 99,06 %

La reducción obtenida se relaciona con la fuerte asociación entre la variable de control U y la variable de interés $f(U)$. La covarianza negativa obtenida indica que, cuando U aumenta, $f(U)$ tiende a disminuir. La corrección realizada mediante el coeficiente $\hat{c}$ aprovecha esta relación para compensar parte de la variabilidad presente en las muestras.

Finalmente, el factor de reducción de varianza puede interpretarse como un *speedup* equivalente de:

$106,5110\times$

Bajo la relación usual de Monte Carlo, donde la varianza del estimador disminuye proporcionalmente a $1/N$, este valor indica que Monte Carlo simple necesitaría aproximadamente 106,511 veces más evaluaciones para alcanzar una varianza comparable a la obtenida mediante variables de control en este experimento. Este *speedup* representa una medida de eficiencia estadística y no un aumento literal en la velocidad de ejecución del programa.

En esta ejecución, el estimador mediante variables de control también presentó un error absoluto menor, pasando de 0,00072513 con Monte Carlo simple a 0,00014337. Sin embargo, al igual que con las variables antitéticas, la efectividad de la técnica se evalúa principalmente mediante la reducción de la varianza y del error estándar, ya que el error absoluto observado en una ejecución particular depende de la muestra pseudoaleatoria generada.

3.5. Cuando un generador arruina el resultado

Los métodos de Monte Carlo dependen de la calidad de los números pseudoaleatorios utilizados durante la simulación. Aunque un generador pueda producir valores que individualmente aparenten estar distribuidos uniformemente, pueden existir dependencias entre valores consecutivos que afecten los resultados cuando estos se utilizan conjuntamente para construir puntos multidimensionales.

Para estudiar este efecto se compararon dos generadores: RANDU y la implementación propia de Mersenne Twister MT19937 utilizada anteriormente. El experimento consistió en estimar mediante Monte Carlo el volumen de la bola unitaria en tres dimensiones.

1. Estimación del volumen mediante Monte Carlo

La bola unitaria en tres dimensiones está definida como:

$$B_3 = \{(x, y, z) \in \mathbb{R}^3 : x^2 + y^2 + z^2 \leq 1\}.$$

Su volumen teórico es:

$$V_3 = \frac{4}{3}\pi.$$

Por lo tanto:

$$V_3 \approx 4,18879020$$

Para realizar la estimación se generaron puntos dentro del cubo:

$$[0, 1]^3.$$

Cada punto tridimensional se construyó utilizando tres valores pseudoaleatorios consecutivos:

$$(x_i, y_i, z_i) = (U_{3i}, U_{3i+1}, U_{3i+2}).$$

Un punto pertenece a la porción de la bola unitaria contenida en el primer octante cuando:

$$x_i^2 + y_i^2 + z_i^2 \leq 1.$$

La proporción de puntos que cumplen esta condición permite estimar el volumen correspondiente al primer octante de la bola. Debido a la simetría de la esfera, su volumen completo puede obtenerse multiplicando esta proporción por 8.

Si N_{dentro} representa el número de puntos que cumplen la condición y N es el número total de puntos generados, entonces:

$$\hat{p} = \frac{N_{\text{dentro}}}{N}.$$

El estimador utilizado fue:

$$\hat{V}_3 = 8\hat{p} = 8\frac{N_{\text{dentro}}}{N}$$

Como la pertenencia de cada punto a la bola puede representarse mediante una variable Bernoulli, el error estándar estimado se calculó mediante:

$$\widehat{SE}(\hat{V}_3) = 8\sqrt{\frac{\hat{p}(1-\hat{p})}{N}}.$$

El intervalo de confianza del 95 % se calculó como:

$$IC_{95\%} = \hat{V}_3 \pm 1,96\widehat{SE}(\hat{V}_3).$$

Para el experimento se utilizaron:

$$N = 100000$$

puntos tridimensionales. Como cada punto requiere tres valores pseudoaleatorios, cada generador produjo:

$$3N = 300000$$

valores. En ambos casos se utilizó la misma semilla:

$$8103$$

De esta manera, RANDU y MT19937 fueron comparados utilizando el mismo número de puntos y las mismas condiciones generales del experimento.

2. Resultados obtenidos

Los resultados obtenidos mediante ambos generadores fueron los siguientes:

Generador	Dentro	Estimación	Error estándar	IC 95 %	Error absoluto
RANDU	52537	4.20296000	0.01263282	[4,17819968, 4,22772032]	0.01416980
MT19937	52464	4.19712000	0.01263374	[4,17235787, 4,22188213]	0.00832980

Cuadro 8: Comparación de RANDU y MT19937 para la estimación del volumen de la bola unitaria en tres dimensiones.

El valor teórico:

$$V_3 \approx 4,18879020$$

se encuentra dentro de los intervalos de confianza obtenidos mediante ambos generadores. Para RANDU se obtuvo:

$$\hat{V}_{RANDU} = 4,20296000$$

con un error absoluto de:

$$|4,20296000 - 4,18879020| = \boxed{0,01416980}.$$

Por otro lado, utilizando MT19937 se obtuvo:

$$\hat{V}_{MT} = 4,19712000$$

con un error absoluto de:

$$|4,19712000 - 4,18879020| = \boxed{0,00832980}.$$

En esta ejecución, el error absoluto obtenido mediante RANDU fue:

$$\frac{0,01416980}{0,00832980} \approx \boxed{1,7011}$$

veces el error absoluto obtenido mediante MT19937.

Sin embargo, este resultado corresponde a una ejecución particular y no permite concluir por sí solo que RANDU producirá siempre un error 1,7011 veces mayor. La diferencia más importante entre ambos generadores se observa al estudiar la estructura tridimensional de los valores producidos.

3. Estructura tridimensional de RANDU

RANDU es un generador congruencial lineal multiplicativo definido mediante:

$$V_{n+1} = 65539V_n \pmod{2^{31}}.$$

Los valores normalizados utilizados en el experimento se obtienen mediante:

$$U_n = \frac{V_n}{2^{31}}.$$

Para observar las relaciones existentes entre valores consecutivos se formaron ternas:

$$(U_i, U_{i+1}, U_{i+2}).$$

Estas ternas fueron representadas en un espacio tridimensional.

Puntos tridimensionales generados por RANDU




Figura 4: Ternas consecutivas generadas mediante RANDU.

En la gráfica puede observarse que los puntos generados por RANDU no llenan el espacio tridimensional de manera aparentemente uniforme. En cambio, se organizan sobre una serie de planos paralelos claramente visibles.

Esta estructura se debe a las relaciones lineales existentes entre valores consecutivos producidos por RANDU. En particular, las ternas generadas por este algoritmo satisfacen una relación de la forma:

$$U_{i+2} - 6U_{i+1} + 9U_i \approx k,$$

donde k toma solamente un conjunto reducido de valores enteros.

Por lo tanto, los puntos tridimensionales producidos por RANDU se concentran sobre un número reducido de planos en lugar de distribuirse libremente por todo el cubo.

Este comportamiento representa un problema importante para Monte Carlo. Cuando varios números pseudoaleatorios consecutivos se utilizan como coordenadas de un mismo punto, las dependencias del generador se transforman directamente en una estructura geométrica dentro del espacio de muestreo.

4. Comparación con MT19937

El mismo procedimiento se realizó utilizando la implementación propia de Mersenne Twister MT19937. Nuevamente se formaron puntos tridimensionales utilizando valores consecutivos:

$$(U_i, U_{i+1}, U_{i+2}).$$

La distribución obtenida fue:

Puntos tridimensionales generados por MT19937




Figura 5: Ternas consecutivas generadas mediante Mersenne Twister MT19937.

A diferencia de RANDU, en la representación tridimensional de MT19937 no se observa la misma organización de los puntos sobre planos paralelos. Los puntos presentan una distribución visualmente más homogénea dentro del cubo.

La comparación de ambas gráficas permite observar una diferencia que no necesariamente resulta evidente al analizar únicamente cada valor pseudoaleatorio de manera individual. RANDU puede generar valores dentro del intervalo esperado y aun así presentar fuertes dependencias entre valores consecutivos.

En una simulación multidimensional estas dependencias son especialmente importantes, ya que las coordenadas de los puntos suelen construirse a partir de números consecutivos del generador.

5. Efecto sobre la estimación de Monte Carlo

El experimento muestra por qué la calidad del generador pseudoaleatorio es importante para los métodos de Monte Carlo.

El estimador del volumen supone que los puntos utilizados para explorar el espacio de muestreo se comportan como muestras uniformes e independientes. Sin embargo, la estructura observada en RANDU muestra que sus coordenadas consecutivas presentan dependencias que restringen los puntos a determinados planos.

Como consecuencia, algunas regiones del espacio pueden ser exploradas de forma diferente a lo que se esperaría bajo un muestreo verdaderamente independiente. Esto puede afectar las proporciones calculadas por el método de Monte Carlo y, por lo tanto, las estimaciones obtenidas.

En esta ejecución se obtuvo:

$$\text{Error RANDU} = 0,01416980$$

y:

$$\text{Error MT19937} = 0,00832980.$$

RANDU presentó un error absoluto aproximadamente 1,7011 veces mayor que MT19937. No obstante, la evidencia principal del problema de RANDU no es solamente esta diferencia numérica, ya que el error absoluto puede cambiar entre ejecuciones. La evidencia más clara es la estructura geométrica sistemática observada en las ternas consecutivas.

Por lo tanto, un generador puede aparentar un comportamiento adecuado en pruebas simples o unidimensionales y aun así presentar dependencias que se vuelven evidentes al utilizar sus valores en dimensiones mayores.

Este experimento muestra que en Monte Carlo no solamente es importante generar una cantidad suficiente de muestras, sino también utilizar un generador con propiedades adecuadas para el problema. Un generador con dependencias estructurales puede introducir patrones artificiales en el espacio de muestreo y afectar la confiabilidad de los resultados obtenidos.

Referencias

- https://en.wikipedia.org/wiki/Antithetic_variates
- <https://metricgate.com/blogs/antithetic-variates-monte-carlo/>
- <https://vegapit.com/article/montecarlo-variance-reduction-techniques/>
- https://en.wikipedia.org/wiki/Control_variates
- <https://www.youtube.com/watch?v=y67Q1aY8B2s>